

Sports Performance Intelligence

PROGRAMACIÓN INTELIGENCIA ARTIFICIAL

LUIS LIÉBANAS ÁVILA

1. Introducción

Sports Performance Intelligence es una aplicación que analiza el rendimiento de jugadores y equipos de baloncesto a lo largo de una temporada completa. A partir de los datos de cada partido, calcula estadísticas individuales y de equipo, detecta patrones de rendimiento (rachas, partidos excepcionales, caídas de forma), agrupa a los jugadores según su estilo de juego mediante inteligencia artificial, y presenta todos los resultados en un panel interactivo desde el que también se pueden exportar en distintos formatos.

El deporte elegido ha sido el baloncesto, en concreto la NBA, centrando el análisis en 8 equipos de la temporada 2025-26: Boston Celtics, Dallas Mavericks, Denver Nuggets, Golden State Warriors, Los Angeles Lakers, Milwaukee Bucks, Oklahoma City Thunder y Philadelphia 76ers.

2. El dataset utilizado

Para este proyecto se ha combinado dos fuentes de datos complementarias:

Datos reales

Estadísticas oficiales de la temporada 2025-26 de los 8 equipos elegidos, con un total de 164 jugadores. Incluyen su posición, edad, altura, peso y sus medias de la temporada (puntos, rebotes, asistencias, porcentajes de tiro, etc.), además de varias métricas avanzadas y el porcentaje de acierto por zona de la cancha.

Datos generados

El dataset real ofrece medias de toda la temporada, pero no estadísticas partido a partido. Para poder analizar rachas, evolución a lo largo de la temporada o partidos atípicos, era necesario tener un dato por cada jugador y cada partido. Por eso se ha generado una mini-temporada de 112 partidos (28 jornadas), donde cada jugador tiene una estadística de partido que varía de forma realista alrededor de su media real (algunos partidos mejores, otros peores, con alguna actuación excepcional incluida a propósito).

De esta forma, el resultado final combina la fiabilidad de los datos reales (nombres, posiciones, medias de temporada) con el nivel de detalle que necesita el resto del análisis.

En total, el proyecto trabaja con 4 ficheros relacionados entre sí: equipos, jugadores, partidos y estadísticas de cada jugador en cada partido. Esta misma información se guarda también en una base de datos (SQLite), para poder cargarla tanto desde ficheros como desde una base de datos.

3. Estructura del proyecto

El proyecto está organizado en carpetas según su función:

- data/raw — los datos originales, tal y como se obtuvieron, antes de limpiarlos
- data/processed — los datos ya limpios y preparados, listos para usar (equipos, jugadores, partidos, estadísticas)
- src/ — todo el código que realiza los cálculos: limpieza, métricas, análisis, inteligencia artificial y exportación
- app.py — el panel interactivo (dashboard)
- reports/ — carpeta donde se guardan los informes exportados

- notebooks/ — espacio para pruebas y exploración de datos
- requirements.txt y README.md — dependencias e instrucciones de uso

4. Cómo funciona todo, paso a paso

El proyecto se ha construido como una cadena de pasos, cada uno con su propio fichero de código, de forma que cada parte se puede revisar y ejecutar por separado:

1. Se cargan los datos originales de baloncesto y se filtran a los 8 equipos y la temporada elegida.
2. Se limpian los datos (valores que faltan, duplicados, fechas, nombres...) y se genera la mini-temporada de partidos.
3. Se calculan las métricas de cada jugador y de cada equipo.
4. Se generan rankings, comparativas y comparaciones frente a la media de cada posición.
5. Se detectan rachas, partidos atípicos, caídas de rendimiento y jugadores que se salen de lo normal.
6. Se agrupa a los jugadores por estilo de juego mediante un algoritmo de inteligencia artificial.
7. Todo lo anterior se muestra en un panel interactivo, con filtros por equipo, rol y jugador.
8. Desde ese mismo panel se pueden exportar los resultados en CSV, Excel, imágenes PNG o un informe en PDF.

5. Limpieza y preparación de los datos

Antes de poder analizar los datos, ha sido necesario revisar y corregir varios problemas habituales en datos reales:

- Valores que faltaban: cuando un jugador no había intentado ningún tiro de un tipo (por ejemplo, triples), su porcentaje de acierto venía vacío. Se ha rellenado con 0, ya que 0 intentos equivale a 0% de acierto.
- Datos duplicados: varios jugadores cambiaron de equipo a mitad de temporada y aparecían dos o tres veces (una por cada equipo). Se ha decidido quedarse con el equipo en el que disputaron más partidos.
- Fechas: las fechas de los partidos venían en dos formatos distintos (por ejemplo, 09/12/2025 y 2025-12-09). Se han unificado todas a un único formato.
- Categorías: las posiciones de los jugadores se han normalizado a cinco roles consistentes (base, escolta, alero, ala-pívot, pívot), usados en todos los análisis.
- Nombres: se han limpiado espacios y caracteres extraños en los nombres de jugadores y equipos.
- Valores extraños (outliers): se ha comprobado que no hubiera datos imposibles (por ejemplo, más minutos de los que dura un partido) y se han revisado los valores estadísticamente más altos o más bajos de cada variable.

Todas estas comprobaciones se han implementado como funciones genéricas y reutilizables, de forma que se aplican igual a los distintos ficheros de datos, y se acompañan de validaciones automáticas que confirman que el resultado final es correcto.

6. Métricas calculadas

Se calculan tres tipos de métricas: individuales (por jugador), colectivas (por equipo) y avanzadas.

Tipo	Métrica	Qué representa
Individual	Minutos jugados	Tiempo en pista, por partido y en total
Individual	Tiros por partido / por 36 min	Cuántos tiros intenta, ajustado al tiempo jugado
Individual	Puntos por partido	Anotación media
Individual	Asistencias	Pases que terminan en canasta
Individual	Precisión de pase	Asistencias por cada pérdida de balón
Individual	Eficiencia ofensiva (TS%)	Acierto real, contando tiros de 2, 3 y libres
Individual	Recuperaciones defensivas	Robos de balón por partido
Equipo	Posesiones medias	Cuántas veces ataca el equipo por partido
Equipo	Rendimiento local/visitante	Diferencias jugando en casa o fuera
Equipo	Comparación entre equipos	Ranking de los 8 equipos
Equipo	Evolución temporal	Cómo cambia el rendimiento jornada a jornada
Avanzada	Puntos esperados por tiro	Calidad del tiro según la zona de la cancha
Avanzada	Eficiencia por zona	Acierto en la zona donde más tira cada jugador
Avanzada	Índice de consistencia	Qué tan regular es un jugador partido a partido
Avanzada	Presión defensiva	Robos + tapones, ajustado a 36 minutos

7. Inteligencia artificial utilizada

Agrupación por estilo de juego (clustering)

Se ha utilizado un algoritmo de agrupación automática (K-Means) para clasificar a los jugadores con más minutos en 4 grupos según su estilo de juego, sin indicarle de antemano qué grupos buscar.

Perfil	Qué lo caracteriza	Ejemplos
Finalizador	Mucha anotación y peso ofensivo	Luka Dončić, Tyrese Maxey
Creador	Muchas asistencias en relación a sus minutos	Derrick White, Payton Pritchard
Recuperador	Mucho rebote, robos y tapones	Anthony Davis, Chet Holmgren
Jugador equilibrado	Aporta de forma repartida, sin destacar en un área	Paul George, Kelly Oubre Jr.

Para poder mostrar a los jugadores en un mapa visual de dos dimensiones, se ha usado una técnica llamada PCA, que resume todas sus estadísticas en solo dos coordenadas, manteniendo la mayor parte de la información posible.

Detección de anomalías (Isolation Forest)

Para detectar partidos fuera de lo común teniendo en cuenta varias estadísticas a la vez (minutos, puntos, rebotes, asistencias, robos, tapones y pérdidas), se ha usado un segundo algoritmo, Isolation Forest. Este algoritmo aprende qué es un partido «normal» para el conjunto de jugadores y señala automáticamente aquellos que se salen claramente de lo habitual, complementando la detección de rachas y partidos atípicos basada en estadística clásica (media, desviación típica y z-score).

8. Problemas encontrados y decisiones tomadas

- Jugadores repetidos por traspaso: al filtrar los datos reales, algunos jugadores aparecían varias veces por haber cambiado de equipo durante la temporada. Se decidió conservar una sola fila por jugador, la del equipo en el que disputó más partidos, y documentar este criterio.
- Falta de datos por partido: el dataset real solo incluía medias de temporada. Se resolvió generando una mini-temporada sintética, calibrada con las medias reales de cada jugador, en lugar de usar valores aleatorios sin relación con la realidad.
- El agrupamiento por estilo de juego no encontraba el perfil «Creador»: en una primera versión, los grupos se formaban según el volumen total de estadísticas (titulares frente a suplentes), y ningún grupo representaba a los jugadores «creadores de juego». Se resolvió cambiando las variables usadas: en lugar de medias por partido, se utilizaron tasas «por 36 minutos», que reflejan mejor el estilo de juego independientemente de los minutos que juegue cada jugador. Con este cambio, los 4 perfiles esperados aparecieron de forma clara.

9. Conclusiones

El proyecto cubre el ciclo completo de un sistema de análisis deportivo: ingestión y limpieza de datos, cálculo de métricas individuales, colectivas y avanzadas, análisis comparativo, detección de patrones y anomalías, segmentación mediante inteligencia artificial, un panel interactivo con filtros y exportación de resultados en varios formatos.

La combinación de datos reales (jugadores, equipos, posiciones y medias de temporada) con datos generados de forma controlada (partido a partido) ha permitido cubrir todos los requisitos sin perder realismo: los nombres, equipos y perfiles de juego corresponden a la temporada real, mientras que el detalle partido a partido permite el análisis de rachas y anomalías que el dataset original no ofrecía.

Como posibles ampliaciones futuras, el proyecto podría incorporar varias temporadas para analizar la evolución de los jugadores a largo plazo, datos de tracking (posiciones en la cancha) si estuvieran disponibles, o desplegarse en la nube (Streamlit Community Cloud) para su uso sin necesidad de instalación.